


База теории вероятностей

Дискретное вероятностное пространство



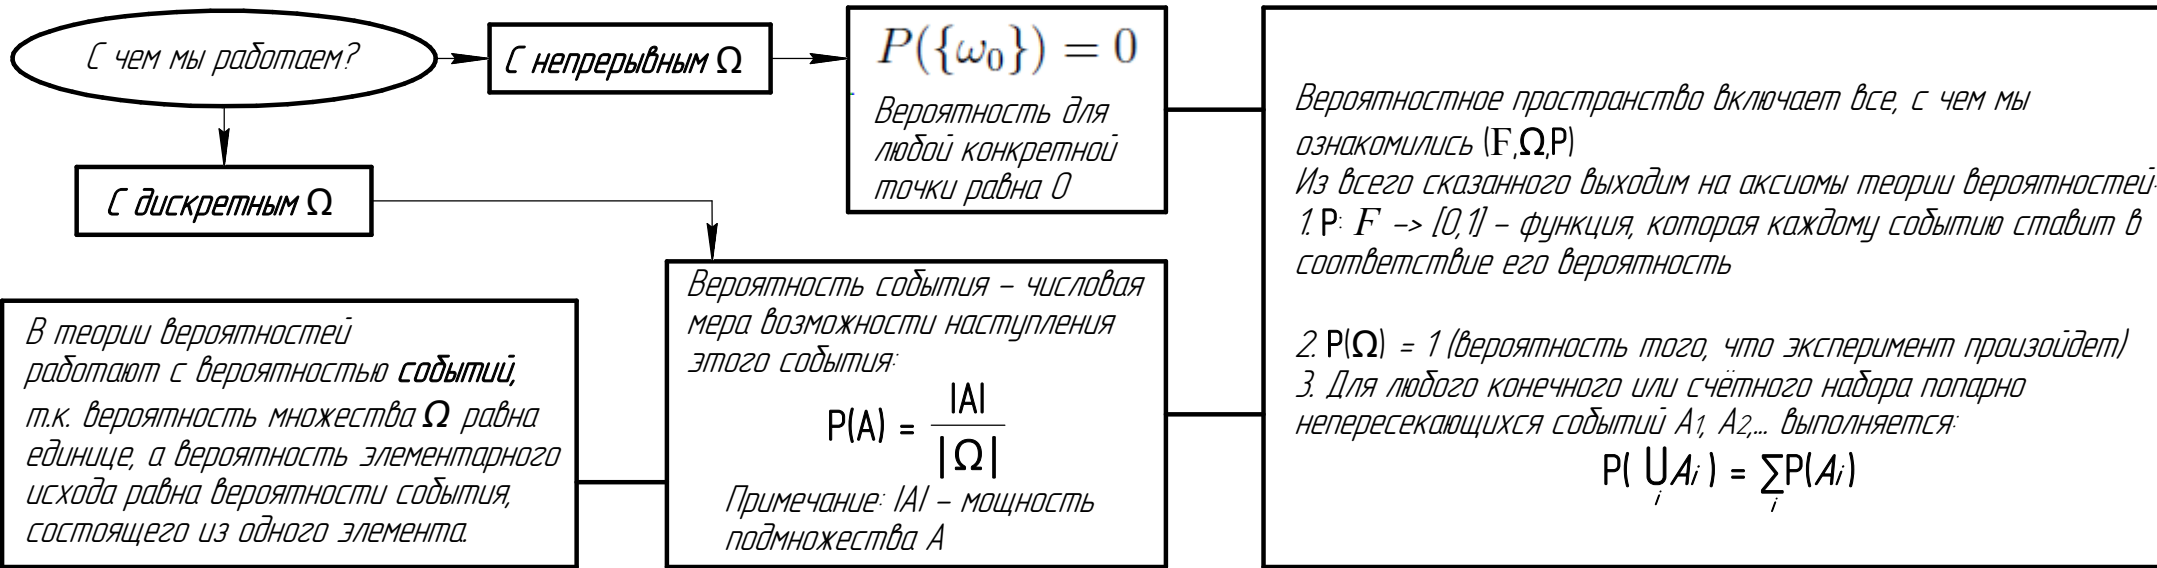
Пространство элементарных исходов
(множество Ω) – множество, содержащее все
возможные взаимоисключающие результаты
эксперимента



Событие A (обычно события обозначают
буквой лат. алфавита) – подмножество
множества Ω , содержащее часть
результатов эксперимента
 \mathcal{F} – сигма-алгебра событий,
множество всех событий
(мощность равна 2^{Ω} , т.е. $|\mathcal{F}| = 2^{\Omega}$)



Элементарный исход w_i – единичный
мельчайший неделимый результат
эксперимента



Случайная величина

Случайная величина – это функция $X: \Omega \rightarrow R$, измеримая относительно сигма-алгебры F и борелевской сигма-алгебры на R . Звучит страшно, однако по факту это число, которое получается в результате случайного эксперимента. Выпадение орла при броске монеты, например (обозначим выпадение орла за 1, а решки за 0).

Закодировали орел как 1, решку как 0, но как еще можно представить случайную величину?

дискретный случай


Плотность распределения (PDF)
(для непрерывного случая)

$$f_X(x) = \frac{dF_X(x)}{dx}$$


– производная F -ии распределения
Тогда вероятность случайной величины попасть в промежуток от a до b :

$$P(a < X \leq b) = \int_a^b f_X(x) dx$$


Эмпирическая функция распределения
много-много раз проделали эксперимент – получили теор. F -ию распределения:



По теореме Гливенко – Кантелли эмпирическая функция распределения сходится к истинной равномерно почти наверное



Теоритическая функция распределения



дискретный случай

непрерывный случай

Функция распределения (CDF)

$$F_X(x) = P(X \leq x)$$

Свойства:

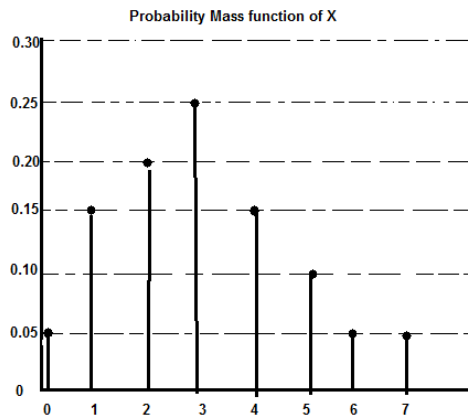
1. Неубывающая
2. $\lim_{x \rightarrow -\infty} F_X(x) = 0$, $\lim_{x \rightarrow +\infty} F_X(x) = 1$
3. Справа непрерывна

Значение функции распределения $F(x)$ показывает долю всех возможных исходов эксперимента, при которых случайная величина X принимает значения, меньшие или равные x . Например, если мы говорим о температуре воздуха, то $F(20^\circ C)$ покажет вероятность того, что температура окажется ниже или равной $20^\circ C$

Табличный способ (PMF)

X	x_1	x_2	\dots	x_n
$P(X = x_i)$	p_1	p_2	\dots	p_n

P.S. Конечно же, $\sum p_i = 1$



Числовые характеристики случайных величин

Что еще за моменты?

Моменты нужны для определения поведения случайной величины. 1-ый момент показывает среднее по вероятности значение, 2-ой – разброс данных, 3-ий – насколько кривая распределения наклоняется вправо или влево (асимметрия), 4-ый – насколько острый пик у кривой (эксцесс).

Начальные моменты
 k -ым начальным моментом называется мат. ожидание от случайной величины в степени k : $\nu_k = \mathbb{E}[X^k]$
Например, первый начальный момент – то самое мат. ожидание

Центральные моменты
 k -ым центральным моментом называется следующая величина:

$$\mu_k = \mathbb{E}[(X - \mathbb{E}[X])^k]$$

Например,
2-ой центральный момент – $\text{var}(X)$
3-ий – асимметрия, 4-ый – эксцесс
т.е. центральный момент описывает поведение с.в. относительно среднего значения

Математическое ожидание (дискретное)

Смысл: средневзвешенный по вероятности арифметический результат повторяющегося эксперимента. (складываем произведения возможных результатов с соответствующей вероятностью)

$$\mathbb{E}[X] = \sum_{k=1}^n x_k P(X = x_k)$$

Математическое ожидание (непрерывное)

Смысл: "центр тяжести" под графиком плотности. По сути (из определения интеграла) мы точно также складываем произведения случайной величины и ее вероятности.

$$\mathbb{E}[X] = \int_{-\infty}^{+\infty} x f_X(x) dx = \int x dF_X(x)$$

Свойства мат. ожидания:

- $Mc = c$
- $M(cX) = cMX$
- $M(X + Y) = MX + MY$
- $M(X \cdot Y) = MX \cdot MY$

Дисперсия

– мера разброса данных

$$\text{Var}(X) = \mathbb{E}[(X - \mathbb{E}[X])^2]$$

+ среднеквадратичное отклонение – корень из дисперсии, данная статистика интерпретируется, так как имеет ту же размерность, что и случайная величина.


$$\sigma_X = \sqrt{\text{Var}(X)}$$

Свойства дисперсии:

- $\text{Var}(c) = 0$
- $\text{Var}(aX) = a^2 \text{Var}(X)$
- $\text{Var}(X + c) = \text{Var}(X)$
- $X = \mathbb{E}[X]$ п.н. $\iff \text{Var}(X) = 0$
- $\text{Var}(X + Y) = \text{Var}(X) + \text{Var}(Y)$

ладно

– Жак Фреско –



моментов бесконечно много, но самые частоиспользуемые – первые два

Наиболее полезные распределения случайных величин


Распределение Бернулли

Случайная величина $X \sim \text{Bernoulli}(p)$, если принимает только два значения: 1 ("успех") с вероятностью p , 0 ("неудача") с вероятностью $q = 1 - p$

Функция вероятности (PMF):

$$P(X = k) = \begin{cases} p & \text{при } k = 1 \\ 1 - p & \text{при } k = 0 \\ 0 & \text{иначе} \end{cases} \quad \text{или} \quad P(X = k) = p^k(1-p)^{1-k} \quad \text{для } k \in \{0, 1\}$$

Функция распределения вероятности (CDF):



Числовые характеристики:

$$E[X] = p$$

$$\text{Var}(X) = p(1 - p)$$

Применение:

- Моделирование одного испытания с бинарным исходом
- Анализ успеха/неудачи единичного события

Относится к классу дискретных случайных величин


Биномиальное распределение

Случайная величина $X \sim \text{Bin}(n, p)$, если описывает число успехов в n независимых испытаниях. Бернулли с одинаковой вероятностью успеха p в каждом.

Функция вероятности (PMF):

$$P(Y = k) = \binom{n}{k} p^k (1 - p)^{n-k}, \quad k = 0, 1, 2, \dots, n$$

Функция распределения вероятности (CDF):



Числовые характеристики:

$$E[X] = np$$

$$\text{Var}(X) = np(1 - p)$$

Применение:

- Моделирование нескольких (n) испытаний с бинарным исходом
- Число успешных операций из n проведенных

Относится к классу дискретных случайных величин

частный случай
 $n = 1$


Здесь важно понимать, что речь идет о **независимых** экспериментах. Две случайные величины X и Y называются **независимыми**, когда результат одной не влияет на результат второй. Более формально совместная вероятность двух событий равна произведению вероятностей: $P(X, Y) = P(X) \cdot P(Y)$

Пуассоновское распределение

Что будет, если взять биномиальное распределение при $n \rightarrow \infty$, $p \rightarrow 0$, $\lambda = np = \text{const}$ (мат. ожидание/среднее количество успехов из бин. распр.) и подставить все это добро в формулу биномиального распределения? Все верно, мы получим распределение Пуассона, PMF для которого выглядит следующим образом:

$$P(X = m) = \frac{\lambda^m e^{-\lambda}}{m!}, \quad m = 0, 1, 2, \dots$$

Функция распределения (CDF)



Числовые характеристики:

$$E[X] = \lambda$$

$$\text{Var}(X) = \lambda$$

Применение:

- Системы массового обслуживания: вероятность m звонков за время t :

$$P(N_t = m) = \frac{(\lambda t)^m e^{-\lambda t}}{m!}$$


Относится к классу дискретных случайных величин

Экспоненциальное распределение

На этот раз уже используем пуассоновский поток с интенсивностью λ интервалы между событиями T имеют экспоненциальное распределение $T \sim \text{Exp}(\lambda)$

Функция распределения CDF:


$$F_T(t) = 1 - e^{-\lambda t}$$



Важной особенностью этого распределения является **отсутствие памяти**. Например, вероятность, что звонок придет через 2 минуты, не зависит от того, ждали ли вы уже 5 минут.

Плотность вероятности PDF:

$$f_T(t) = \frac{d}{dt} F_T(t) = \lambda e^{-\lambda t}, \quad t \geq 0$$



Числовые характеристики:

$$E[X] = \frac{1}{\lambda}$$

$$\text{Var}(X) = \frac{1}{\lambda^2}$$

Применение:

- Системы массового обслуживания: каждый оператор обрабатывает звонок за экспоненциальное время


Относится к классу дискретных случайных величин

Равномерное распределение

Равномерное распределение описывает ситуацию, где все возможные исходы равновероятны.


CDF:

$$F(x) = \begin{cases} 0 & x \leq a \\ \frac{x-a}{b-a} & x \in [a, b] \\ 1 & x \geq b \end{cases}$$



PDF:

$$f(x) = \begin{cases} \frac{1}{b-a} & x \in [a, b] \\ 0 & x \notin [a, b] \end{cases}$$



Числовые характеристики:

$$E[X] = \frac{a+b}{2}$$
$$Var(X) = \frac{(b-a)^2}{12}$$

Применение:

- Генерация случайных чисел
- Равномерное заполнение области точками для создания текстур


Относится к классу дискретных случайных величин

Нормальное распределение (Гаусс)

Нормальное распределение – очень важное распределение в теории вероятностей и мат. статистике.


Случайная величина $X \sim N(\mu, \sigma^2)$, если её функция плотности PDF имеет вид:

$$f(x) = \frac{1}{\sigma\sqrt{2\pi}} \exp\left(-\frac{(x-\mu)^2}{2\sigma^2}\right), \quad x \in \mathbb{R}$$



Функция распределения вероятностей CDF:

$$\Phi(x) = \frac{1}{\sqrt{2\pi}} \int_{-\infty}^x e^{-t^2/2} dt$$



Относится к классу непрерывных случайных величин

Нормальное распределение характеризуется μ и σ^2

Если $\mu = 0, \sigma^2 = 1$

Его плотность:

$$\varphi(x) = \frac{1}{\sqrt{2\pi}} e^{-\frac{x^2}{2}}$$

Числовые характеристики:

$$E[X] = \mu$$

$$Var(X) = \sigma^2$$

Применение:

- В измерениях (ошибки часто распределены нормально)
- В физике и инженерии (шум)
- В финансах (доходности акций часто моделируются нормальными распределениями)

Распределение Парето

Распределение Коши

Распределение Коши

Распределение Коши возникает, например, при рассмотрении отношения двух независимых нормальных случайных величин. Пусть $X \sim N(0, 1)$, $Y \sim N(0, 1)$, X, Y независимы, тогда рассмотрим:

$$Z = \frac{X}{Y}$$


PDF для Z : $f_{X,Y}(x,y) = \frac{1}{2\pi} e^{-\frac{x^2+y^2}{2}}$

many, many mathematical transformations later...

Таким образом, плотность распределения Коши:


$$f(x) = \frac{1}{\pi(1+x^2)}, \quad x \in \mathbb{R}.$$

график плотности распределения похож на нормальное р-ние, только с тяжелыми хвостами



PDF

CDF



Числовые характеристики:

$E[X]$ – отсутствует

$Var(X)$ – отсутствует

Применение:


- Статистика: устойчивые распределения с тяжёлыми хвостами, моделирование данных с выбросами.
- Математическое моделирование: отношение нормальных величин.

Распределение Парето


Распределение Парето используется для описания величин, имеющих закон 80/20. Его плотность PDF:

PDF:

$$f_X(x) = \begin{cases} \frac{kx_m^k}{x^{k+1}}, & x \geq x_m \\ 0, & x < x_m \end{cases}$$



CDF:



Числовые характеристики:
 $E[X]$ – существует только при $k > 1$

$$E[X] = \frac{kx_m}{k-1}$$

$Var(X)$ – существует только при $k > 2$

$$D[X] = \left(\frac{x_m}{k-1} \right)^2 \frac{k}{k-2}$$

Применение:

- Экономика: распределение богатства (которое гласит: 20% популяции владеет 80% богатства)
- Интернет-трафик: распределение размеров файлов.
- Природные явления: распределение размеров городов, землетрясений.


Теорема Байеса

Условная вероятность

Какова вероятность правильного ответа на вопрос "какое животное я загадал"? Наверное, достаточно маленькая. Однако как изменится эта вероятность, если я добавлю условие "у этого животного есть крылья и клюв". Кажется, вероятность успеха выросла. Это и есть условная вероятность, иначе, вероятность события A при условии выполнения условия B :

$$P(A | B) = \frac{P(A \cap B)}{P(B)}$$

Как можно интерпретировать формулу выше? Например, на кругах Эйлера:




mA – количество исходов множества A
 mB – количество исходов множества B
 mAB – количество исходов пересечения A и B
 n – общее количество исходов

$$P(A) = \frac{mA}{n}, P(B) = \frac{mB}{n}, P(AB) = \frac{mAB}{n}$$

Но по логике $P(A|B) = \frac{mAB}{mB}$ (ведь мы знаем, что событие B точно произошло, тогда $n \rightarrow mB$)

Заметим, что $\frac{P(AB)}{P(B)} = \frac{mAB}{mB}$, вот и формула!

Формула полной вероятности



Как можно представить вероятность события A ? Через условную вероятность!

$$P(A) = \sum_{i=1}^n P(H_i) \cdot P(A | H_i)$$

Формула умножения вероятностей

Справедливо можно заметить, что числитель $P(AB)$ встречается и в $P(A|B)$, и в $P(B|A)$, тогда:

$$P(A \cap B) = P(A | B) \cdot P(B) = P(B | A) \cdot P(A)$$

Теорема Байеса

Объединим предыдущие шаги и получим ее величество теорему Байеса позволяет пересчитывать вероятность гипотезы H_i при условии наступления события A :

$$P(H_i | A) = \frac{P(H_i) \cdot P(A | H_i)}{\sum_{j=1}^n P(H_j) \cdot P(A | H_j)}$$

В машинном обучении Теорема Байеса имеет следующий вид:

ϑ – параметры модели (например, веса нейросети)

D – данные

$P(\vartheta | D)$ – апостериорное распределение (что мы знаем о параметрах после наблюдения данных)

$P(D | \vartheta)$ – правдоподобие (насколько хорошо модель объясняет данные)


$P(\vartheta)$ – априорное распределение (наши знания до наблюдения данных)

$P(\vartheta | D)$ – то, что мы стараемся максимизировать

Формула, которую можно найти в байесовском выводе: $p(\theta|D) = \frac{p(\theta)p(D|\theta)}{p(D)}$

В машинном обучении Байес используется в наивной байесовской модели (буквально фильтруем данные с помощью теоремы байеса с допущением о независимости признаков)

В глубоком обучении существуют байесовские нейросети, где в каждом нейроне зашиты не веса, а распределения с.в.:



Марков, Чебышев, ЗБЧ, ЦПТ

Неравенство Маркова

Пусть X – неотрицательная случайная величина ($X \geq 0$) с конечным математическим ожиданием EX . Тогда для любого $\epsilon > 0$:

$$P(X \geq \epsilon) \leq \frac{EX}{\epsilon}$$

Суть можно понять через пример: пусть X – время ожидания в очереди с $EX = 10$ мин. Вероятность того, что время ожидания превысит 30 мин:

$$P(X \geq 30) \leq \frac{10}{30} = \frac{1}{3}$$

Важные заметки по поводу Маркова:

1. Неравенство Маркова не требует знания распределения X , только его среднее.
2. Оно не всегда точное, но полезно как грубая верхняя оценка.
3. Работает только для неотрицательных случайных величин.

ВСЁ ПРОИЗОШЛО
СЛУЧАЙНО,
КАК И
ПЛАНИРОВАЛОСЬ.

Неравенство Чебышева

Пусть X – случайная величина с конечным математическим ожиданием $\mu = EX$ и конечной дисперсией $\sigma^2 = \text{Var}X$. Тогда для любого $\epsilon > 0$:

$$P(|X - \mu| \geq \epsilon) \leq \frac{\sigma^2}{\epsilon^2}$$

Оба неравенства являются грубыми, но быстрыми оценками (Чебышев более точен), оба оценивают вероятность выбросов с.в.:

Диапазон	Вероятность
$\mu \pm \sigma$	≥ 0
$\mu \pm 2\sigma$	$\geq 1 - \frac{1}{4} = 0.75$
$\mu \pm 3\sigma$	$\geq 1 - \frac{1}{9} \approx 0.888$
$\mu \pm k\sigma$	$\geq 1 - \frac{1}{k^2}$

Марков и Чебышев – это «аварийные» границы, когда у вас нет данных о распределении, но нужно гарантировать, что модель не выйдет за рамки допустимого риска.



Закон больших чисел (ЗБЧ)

С ростом размера выборки среднее арифметическое сходится по вероятности к мат ожиданию ген. совокупности. Более формализованно:

$$\bar{X} = \frac{X_1 + \dots + X_n}{n} \xrightarrow{p} E(X)$$


Примечание: сходимость по вероятности означает

$$\forall \epsilon > 0 \quad P(|X_n - X| < \epsilon) \rightarrow 1 \text{ при } n \rightarrow \infty$$

то есть

$$\lim_{n \rightarrow \infty} P(|X_n - X| < \epsilon) = 1$$

Визуализация ЗБЧ: Среднее значение по кубику в зависимости от размера выборки



Центральная предельная теорема (ЦПТ)

Распределение суммы случайных величин при увеличении их количества имеет распределение, близкое к нормальному. Более формализованно:

$$\frac{X_1 + \dots + X_n}{n} \xrightarrow{d} N\left(E(X), \frac{\text{Var}(X)}{n}\right)$$

Примечание: сходимость по распределению означает

$$\lim_{n \rightarrow \infty} F_{X_n}(x) = F_X(x)$$

то есть при увеличении n эмпирическая случайная величина стремится стать теоретической

Даже если отдельные наблюдения X_i имеют несимметричное, дискретное или "экзотическое" распределение, сумма многих таких наблюдений часто ведёт себя как нормально распределённая величина.

Для разных распределений подходящее значение n будет разным!

ЦПТ не работает, если:

1. Выборка слишком мала
2. Сильная асимметрия данных
3. Бесконечная дисперсия
4. Зависимые случайные величины
5. Слишком тяжёлые хвосты